

Proyecto Análisis UF 2025

Descripción del Proyecto

Proyecto completo de análisis de datos que extrae, limpia y analiza los valores de la Unidad de Fomento (UF) del año 2025 desde el sitio web del Servicio de Impuestos Internos (SII) de Chile.

Objetivos de Aprendizaje

- Extracción de datos desde páginas web usando `pd.read_html()`
- Lectura y escritura de archivos CSV
- Limpieza y preparación de datos
- Análisis estadístico descriptivo con pandas y NumPy
- Exportación de resultados en múltiples formatos

Estructura del Proyecto

proyecto_uf_2025/

|

└─ analisis_uf_2025.ipynb # Notebook principal con todo el análisis

└─ requirements.txt # Dependencias del proyecto

└─ UF_2025.csv # Datos de entrada (valores UF)

└─ GUIA_PASO_A_PASO.md # Guía detallada de implementación

└─ README.md # Este archivo

```
|
└─ Archivos generados (después de ejecutar):
    ├── UF_2025_LIMPIO.csv      # Datos limpios
    ├── UF_2025_ESTADISTICAS.csv # Estadísticas descriptivas
    └─ REPORTE_UF_2025.txt     # Reporte resumido
```

Inicio Rápido

1. Requisitos Previos

- Python 3.8 o superior
- pip (gestor de paquetes de Python)
- Visual Studio Code (recomendado) o Jupyter Notebook
- Conexión a Internet (para extracción de datos web)

****Nota:**** El script ahora usa rutas absolutas, por lo que funciona correctamente incluso si se ejecuta desde directorios diferentes.

2. Instalación

Clonar o descargar el proyecto

```
cd proyecto_uf_2025
```

Crear entorno virtual (opcional pero recomendado)

```
python -m venv venv
```

Activar entorno virtual

Windows:

```
venv\Scripts\activate
```

Mac/Linux:

```
source venv/bin/activate
```

Instalar dependencias

```
pip install -r requirements.txt
```

3. Ejecución

****Opción A: Visual Studio Code****

1. Abrir VS Code
2. Abrir la carpeta del proyecto
3. Abrir ` analisis\_uf\_2025.ipynb `
4. Hacer clic en "Run All"

****Opción B: Jupyter Notebook****

```
jupyter notebook analisis_uf_2025.ipynb
```

****Opción C: JupyterLab****

```
jupyter lab
```

1. Extracción de Datos

- Extracción desde web usando ``pd.read_html()``
- Lectura de archivo CSV local como alternativa

2. Ensuciamiento de Datos

Simulación de problemas reales:

- Valores nulos (NaN)
- Filas duplicadas
- Outliers (valores atípicos)
- Espacios en blanco
- Formatos inconsistentes
- Columnas irrelevantes

3. Limpieza de Datos

- Eliminación de duplicados
- Conversión de tipos de datos
- Normalización de formatos
- Detección y tratamiento de outliers
- Imputación de valores nulos
- Ordenamiento de datos

4. Análisis Descriptivo

- Estadísticas básicas (media, mediana, desviación estándar)
- Valores extremos por mes
- Variaciones mensuales
- Correlaciones entre meses
- Análisis de tendencias anuales

5. Exportación

- Datos limpios en CSV
- Estadísticas descriptivas en CSV
- Reporte resumido en TXT

Librerías Utilizadas

|-----|-----|-----|

Características Principales

Extracción Automática Web con Validación

```
url = 'https://www.sii.cl/valores_y_fechas/uf/uf2025.htm'
```

```
tablas = pd.read_html(url, decimal=',', thousands='.')
```

```
df_web = tablas[0]
```

Validación inteligente de estructura

```
meses_encontrados = [mes for mes in MESES if mes in df_web.columns]
```

```
if len(meses_encontrados) >= 10: (chilenos y estándar)
```

- Detección inteligente de outliers usando método IQR ($3 \times$ desviación)
- Interpolación lineal para valores nulos
- Conversión segura de tipos de datos
- Manejo de valores con espacios en blanco
- Soporte para caracteres especiales (ñ, á, é, etc.)

```
df = pd.read_csv(ARCHIVO_ENTRADA) # Respaldo a CSV local
```

****Ventaja:**** Si la estructura web cambia, automáticamente usa el archivo CSV local como respaldo.

Limpieza Robusta

- Manejo automático de diferentes formatos
- Detección inteligente de outliers usando IQR
- 7+ métricas estadísticas por mes (promedio, mediana, desv. estándar, etc.)
- Análisis de variación mensual y anual
- Identificación de valores extremos
- Coeficiente de variación para análisis de dispersión

- Resumen anual conompleto
- 15+ métricas estadísticas
- Análisis de correlación
- Detección de tendencias

Ejemplos de Uso

Cargar datos con rutas absolutas

```
import pandas as pd
```

```
import os
```

Rutas absolutas basadas en la ubicación del script

```
script_dir = os.path.dirname(os.path.abspath(__file__))
```

```
archivo_entrada = os.path.join(script_dir, 'UF_2025.csv')
```

Leer CSV

```
df = pd.read_csv(archivo_entrada, sep=';', encoding='utf-8-sig')
```

```
print(f"Datos cargados desde: {archivo_entrada}")
```

Limpiar valores UF (formato chileno)

```
def limpiar_valor_uf(valor):
```

```
    if pd.isna(valor):
```

```
        return np.nan
```

```
    valor_str = str(valor).strip()
```

```
    valor_str = valor_str.replace('.', '')    # Eliminar miles
```

```
    valor_str = valor_str.replace(',', '.')  # Decimal a punto
```

```
    try:
```

```
    return float(valor_str)

except:

    return np.nan
```

```
df['Ene'] = df['Ene'].apply(limpiar_valor_uf)
```

Análisis básico

Estadísticas descriptivas

```
print(df.describe())
```

Valor promedio de UF

```
promedio_anual = df[meses].mean().mean()

print(f"UF Promedio 2025: ${promedio_anual:,.2f}")
```

Detectar outliers con IQR

```
def detectar_outliers(data, columna, k=3):

    """Detecta outliers usando método IQR

    k=3 es método conservador (99.7% de confianza)

    """

    Q1 = data[columna].quantile(0.25)
    Q3 = data[columna].quantile(0.75)
    IQR = Q3 - Q1

    limite_inf = Q1 - k * IQR
    limite_sup = Q3 + k * IQR

    return data[(data[columna] < limite_inf) | (data[columna] > limite_sup)]
```

```
outliers = detectar_outliers(df, 'Ene', k=3)
```

Conceptos Aprendidos

Pandas

- ``read_html()`` Extracción de tablas web
- ``read_csv()`` Lectura de archivos CSV
- ``drop_duplicates()`` Eliminación de duplicados
- ``interpolate()`` Imputación de valores nulos
- ``describe()`` Estadísticas descriptivas
- ``corr()`` Matriz de correlación

NumPy

- ``np.random`` Generación de números aleatorios
- ``np.nan`` Representación de valores nulos
- Operaciones vectorizadas

Limpieza de Datos

- Detección de outliers con IQR
- Normalización de formatos
- Conversión de tipos de datos
- Manejo de valores nulos

Solución de Problemas Comunes

Error: "No module named 'pandas'"

```
pip install pandas numpy
```

Error: "FileNotFoundError: UF_2025.csv not found"

****Causa:**** El script se ejecuta desde otro directorio.

****Solución:**** El script ahora usa rutas absolutas automáticamente. Asegúrate de ejecutar desde la carpeta correcta:

```
cd ruta/al/proyecto
```

```
python analisis_uf_script.py
```

Error al leer HTML: "No tables found"

```
pip install lxml html5lib
```

Si persiste, el script usa automáticamente el CSV local como respaldo.

El notebook no abre

```
pip install --upgrade notebook ipykernel
```

```
jupyter notebook
```



Resultados Esperados

Al finalizar la ejecución, obtendrás 3 archivos en la misma carpeta del proyecto:

1. ****UF_2025_LIMPIO.csv****: Datos limpios y estructurados (34 filas × 13 columnas)
2. ****UF_2025_ESTADISTICAS.csv****: Tabla con todas las métricas (12 meses × 7 estadísticas)
3. ****REPORTE_UF_2025.txt****: Resumen ejecutivo del análisis

Métricas Principales por Mes

- ****Promedio****: Valor medio de UF
- ****Mediana****: Valor del medio
- ****Desv_Std****: Desviación estándar
- ****Mínimo/Máximo****: Valores extremos
- ****Rango****: Diferencia entre máximo y mínimo
- ****CV_%****: Coeficiente de variación (dispersión relativa)

Resumen Anual

- UF inicio (01-Ene): ~\$38,419.17
- UF final (31-Dic): ~\$39,727.96
- Variación anual: +3.41%

Contribuciones

Este es un proyecto educativo. Siéntete libre de:

- Modificar el código
- Agregar visualizaciones
- Experimentar con diferentes datasets
- Compartir mejoras

Recursos Adicionales

- ****Documentación Pandas****: <https://pandas.pydata.org/docs/>
- ****Documentación NumPy****: <https://numpy.org/doc/>
- ****Tutorial Jupyter****: <https://jupyter.org/documentation>
- ****Guía detallada****: Ver `GUIA\_PASO\_A\_PASO.md`

Soporte

Para preguntas o problemas:

1. Revisa la `GUIA\_PASO\_A\_PASO.md`
2. Consulta la sección de Solución de Problemas
3. Revisa la documentación oficial de las librerías

Licencia

Este proyecto es de código abierto y está disponible para fines educativos.

Características Técnicas Importantes

Rutas Absolutas (Portabilidad)

import os

SCRIPT_DIR = os.path.dirname(os.path.abspath(__file__))

ARCHIVO_ENTRADA = os.path.join(SCRIPT_DIR, 'UF_2025.csv')

✅ El script funciona desde cualquier directorio

✅ Perfecto para clonarlo en cualquier máquina

Validación Inteligente de Datos

- Si la web está disponible → Usa datos frescos
- Si la estructura web cambió → Automáticamente respaldo a CSV
- Si ambos fallan → Muestra error claro

Conversión de Tipos Robusta

- Maneja formatos chilenos (38.419,17)
- Maneja formatos internacionales (38419.17)
- Convierte con seguridad a float

Próximos Pasos Sugeridos

1. **Visualización**: Agregar gráficos con matplotlib/seaborn
2. **Análisis temporal**: Estudiar patrones estacionales
3. **Comparación histórica**: Comparar UF 2024 vs 2025
4. **Predicción**: Implementar modelos de series temporales
5. **Dashboard**: Crear un dashboard interactivo con Streamlit o Dash
6. **API**: Exponer los resultados vía API REST con Flask/FastAPI

Cambios Recientes (v1.1)

- ✅ ****Rutas absolutas****: El script ahora funciona desde cualquier directorio
- ✅ ****Validación web inteligente****: Respaldo automático a CSV si la web falla
- ✅ ****Mejor manejo de tipos****: Conversión robusta de datos chilenos
- ✅ ****Soporte completo de rutas****: Compatible con espacios en rutas (OneDrive, etc.)
- ✅ ****Compatibilidad notebook****: Sincronizado con analisis_uf_2025.ipynb

****Versión:**** 1.1

****Fecha:**** Febrero 2026

****Nivel:**** Principiante - Intermedio

****Estado:****  Producción - Probado y funcional

****Autor:**** Analista de Datos

****Fuente de datos:**** Servicio de Impuestos Internos (SII) Chile

¡Feliz análisis de datos!  