

INFORETAIL

Equipo de Análisis de Datos

PROPUESTA DE ANÁLISIS EXPLORATORIO DE DATOS

Informe técnico para orientar el trabajo inicial del proyecto de datos

Empresa	InfoRetail
Elaborado por	Analista de Datos - InfoRetail
Destinatarios	Equipo directivo y analistas
Tema	Análisis Exploratorio de Datos (EDA)

1. ¿Qué es el EDA y cómo se diferencia del IDA?

Análisis Exploratorio de Datos (EDA)

El Análisis Exploratorio de Datos (EDA, por sus siglas en inglés) es el proceso mediante el cual un analista examina un conjunto de datos de forma abierta y sin hipótesis previas definidas, con el objetivo de descubrir patrones, detectar anomalías, comprender la estructura del dataset y generar hipótesis para análisis posteriores. Es una etapa esencialmente descriptiva y visual: se busca 'conocer los datos' antes de aplicar cualquier modelo o técnica estadística avanzada.

En el contexto de InfoRetail, el EDA nos permitirá entender cómo se distribuyen las ventas por sucursal, si existen productos con comportamiento atípico, qué variables están relacionadas entre sí y si hay datos faltantes o inconsistentes que puedan comprometer futuros análisis.

Análisis Inicial de Datos (IDA)

El Análisis Inicial de Datos (IDA) es una etapa más estructurada y con objetivos concretos, orientada a verificar supuestos sobre la calidad y estructura del dataset antes de aplicar un modelo estadístico específico. Mientras que el EDA es abierto y exploratorio, el IDA es más sistemático y verifica condiciones puntuales como: ¿los datos están completos?, ¿las variables tienen el tipo correcto?, ¿se cumplen los supuestos del modelo que se va a usar?

Aspecto	EDA	IDA
Objetivo	Descubrir patrones y generar hipótesis	Verificar supuestos y calidad del dato
Enfoque	Abierto, sin hipótesis previa	Dirigido por objetivos concretos
Técnicas	Visualizaciones, estadísticas descriptivas	Validación de tipos, nulos, outliers
Resultado	Comprensión del dataset	Dataset listo para el modelo

2. Tres Técnicas Exploratorias Clave

A continuación se describen tres técnicas de EDA especialmente útiles para el análisis del dataset de ventas, productos, sucursales y clientes de InfoRetail:

Técnica 1: Histograma	
¿Qué es?	Gráfico de barras que muestra la distribución de frecuencias de una variable numérica continua, dividiendo los datos en intervalos (bins).
¿Qué permite ver?	La forma de la distribución (simétrica, sesgada, bimodal), la concentración de valores, el rango de la variable y la presencia de valores extremos o inusuales.
Aplicación en InfoRetail	Permite visualizar cómo se distribuyen las ventas semanales: si la mayoría de las transacciones se concentran en rangos bajos o si hay clientes con compras muy por encima del promedio.

Técnica 2: Diagrama de Caja (Boxplot)	
¿Qué es?	Representación gráfica que resume la distribución de una variable mostrando la mediana, los cuartiles Q1 y Q3, el rango intercuartílico (IQR) y los valores atípicos (outliers).
¿Qué permite ver?	La dispersión de los datos, la simetría de la distribución y especialmente la presencia de outliers, que son puntos alejados significativamente del resto.
Aplicación en InfoRetail	Resulta ideal para comparar el nivel de ventas entre distintas sucursales o categorías de productos, e identificar sucursales con comportamiento atípico que merezcan atención especial.

Técnica 3: Matriz de Correlación	
¿Qué es?	Tabla (generalmente visualizada como un mapa de calor o heatmap) que muestra el coeficiente de correlación de Pearson entre todos los pares de variables numéricas del dataset.
¿Qué permite ver?	El grado y la dirección de la relación lineal entre variables. Un valor cercano a 1 indica correlación positiva fuerte; cercano a -1, correlación negativa; cercano a 0, ausencia de relación lineal.
Aplicación en InfoRetail	Permite detectar si variables como precio, cantidad vendida, descuento y ticket promedio están relacionadas entre sí, lo cual es fundamental antes de construir modelos predictivos.

3. Herramientas Recomendadas

Para implementar las técnicas descritas, se recomiendan dos herramientas ampliamente utilizadas en la industria del análisis de datos:

Herramienta 1: Python (con pandas, matplotlib y seaborn)

Python es un lenguaje de programación de código abierto y gratuito, ampliamente utilizado en ciencia de datos. Las bibliotecas pandas, matplotlib y seaborn permiten realizar todo el ciclo de EDA desde la carga y limpieza de datos hasta la generación de visualizaciones avanzadas.

Ventajas	Consideraciones
- Gratuito y de código abierto - Alta flexibilidad y control total del análisis - Permite automatizar procesos repetitivos - Escalable a datasets grandes - Integración con modelos de ML	- Requiere conocimientos de programación - Curva de aprendizaje inicial - Las visualizaciones requieren código adicional para personalización

Herramienta 2: Power BI (Microsoft)

Power BI es una herramienta de business intelligence de Microsoft que permite conectar diversas fuentes de datos, construir dashboards interactivos y realizar análisis exploratorio de forma visual, sin necesidad de escribir código. Es especialmente útil para comunicar hallazgos a equipos no técnicos.

Ventajas	Consideraciones
• Interfaz visual intuitiva (drag & drop) • No requiere programación para uso básico • Dashboards interactivos y compartibles • Conexión nativa con Excel, SQL, SharePoint • Ideal para presentaciones ejecutivas	• Versión completa requiere licencia paga • Menor flexibilidad para análisis estadístico avanzado • Procesamiento limitado en datasets muy grandes

4. Conclusión: ¿Por qué hacer EDA antes de cualquier análisis complejo?

"Los datos bien explorados son la mitad del análisis resuelto"

Realizar un EDA antes de cualquier análisis complejo no es un paso opcional, sino una práctica fundamental que determina la calidad de todos los resultados posteriores. Los motivos son concretos y directamente relevantes para InfoRetail:

- Detectar problemas de calidad temprano: Valores faltantes, duplicados o inconsistencias encontradas durante el EDA evitan que errores se propaguen a modelos y dashboards finales, donde serían mucho más costosos de corregir.
- Comprender la naturaleza de los datos: Antes de aplicar una regresión, un clustering o cualquier modelo, es indispensable saber cómo se distribuyen las variables, si hay outliers y cómo se relacionan entre sí.
- Evitar conclusiones incorrectas: Un modelo construido sobre datos mal entendidos puede generar recomendaciones incorrectas para el negocio. El EDA actúa como un filtro de validez previo.
- Generar hipótesis de negocio: Muchas veces los patrones más interesantes emergen del EDA, orientando preguntas que el equipo ni siquiera había contemplado inicialmente.
- Facilitar la comunicación: Las visualizaciones generadas en el EDA son herramientas poderosas para comunicar el estado del dataset al equipo directivo de InfoRetail, sin necesidad de tecnicismos.

En definitiva, el EDA es la base sobre la que se construye cualquier proyecto de datos sólido. Para InfoRetail, esta etapa garantizará que las decisiones comerciales sobre ventas, productos, sucursales y

clientes estén fundamentadas en datos **comprendidos, limpios y bien interpretados**, y no simplemente en datos disponibles.