

■ INFORME TÉCNICO DE ANÁLISIS EXPLORATORIO DE DATOS

Gaming Ratings Database — IGDB Top 150

Módulo 4: Análisis Exploratorio de Datos | Alkemy

Empresa: ComercioYA — Dirección de Análisis Estratégico

Fecha: 17 de febrero de 2026

RESUMEN DEL PROYECTO

Dataset	gaming-ratings-database-20260217.csv
Registros	150 juegos con rating IGDB
Variables	6 columnas originales (1 corrupta detectada)
Variable objetivo	igdb_rating (numérica continua, rango 93.8–100)
Herramientas	Python · Pandas · NumPy · Seaborn · Matplotlib · Scikit-learn
Metodología	EDA completo: IDA · Estadística · Correlación · Regresión · Viz

1. Análisis Inicial de Datos (IDA) — Lección 1

El dataset fue cargado desde el archivo CSV generado el 17 de febrero de 2026, conteniendo información de los 150 juegos mejor calificados en la plataforma IGDB (Internet Game Database). A continuación se detalla la estructura del dataset y los hallazgos del análisis inicial.

1.1 Estructura del Dataset

Variable	Tipo	Subtipo	Nulos	Observaciones
name	Categórica	Nominal	0 (0%)	Nombre del juego
slug	Categórica	Nominal	0 (0%)	Identificador URL único
igdb_rating	Numérica	Continua	0 (0%)	Rating 0–100 — Variable principal
genres	Categórica	Nominal (lista)	1 (0.7%)	Lista de géneros del juego
platforms	Categórica	Nominal (lista)	58 (38.7%)	■■ Alta tasa de nulos
developers	Categórica	Nominal (lista)	62 (41.3%)	■■ Alta tasa de nulos
release_year	—	—	—	■ Columna corrupta (artefacto CSV)

■ **HALLAZGO CRÍTICO** — `release_year`: La columna "release_year" contiene la primera palabra del nombre de cada juego (ej: "Resonite", "Grand", "Metal") en lugar de un año numérico. Esto indica un error de generación del CSV. Esta columna fue excluida del análisis cuantitativo y se recomienda regenerarla desde la API de IGDB.

1.2 Tratamiento de Valores Faltantes

Las columnas **platforms** (38.7% de nulos) y **developers** (41.3% de nulos) presentan alta tasa de datos faltantes. Se decidió **no imputar** estos valores ya que la ausencia misma es informativa: indica que el juego no tiene metadatos completos registrados en IGDB. Se creó la variable binaria **tiene_plataforma** (Sí/No) para aprovechar esta información en el análisis.

2. Estadística Descriptiva — Lección 2

Se aplicaron las principales medidas de tendencia central y dispersión sobre la variable numérica principal **igdb_rating**, que representa el puntaje asignado por la comunidad de IGDB a cada juego en una escala de 0 a 100.

2.1 Medidas de Tendencia Central y Dispersión

Medida	Valor	Interpretación
Media (μ)	96.4927	Promedio del dataset
Mediana	96.0000	Valor central — similar a la media
Moda	95.1	Valor más frecuente
Desv. Estándar (σ)	1.9044	Dispersión baja — dataset homogéneo
Varianza	3.6269	Cuadrado de la desv. estándar
Mínimo	93.8	Juego con menor rating del top 150
Máximo	100.0	Rating perfecto (Resonite)
Rango	6.2	Amplitud total
Q1 (25%)	94.90	Primer cuartil
Q2 (50%)	96.00	Mediana
Q3 (75%)	98.30	Tercer cuartil
IQR	3.40	Rango intercuartílico
Percentil 10	94.30	El 10% de juegos tiene rating menor a este
Percentil 90	99.40	El 10% de juegos tiene rating mayor a este
Coef. Variación	1.97%	Variabilidad relativa muy baja
Asimetría (Skew)	0.3403	Distribución levemente asimétrica
Curtosis	-1.3351	Distribución más apuntada que normal

2.2 Histograma de Distribución y Bandas de Rating




Figura 1: Distribución del Rating IGDB y agrupación por bandas.

2.3 Boxplot y Detección de Outliers

Se aplicó el método IQR para detectar valores atípicos. Con $Q1=94.90$, $Q3=98.30$ e $IQR=3.40$, los límites son: **inferior=89.80** y **superior=103.40**. No se detectaron outliers en el dataset, lo cual es consistente con tratarse de los 150 juegos de mayor calidad global.




Figura 2: Boxplot general y por género principal.

3. Análisis de Correlación — Lección 3

Se calculó la matriz de correlación de Pearson entre todas las variables numéricas disponibles. Las variables numéricas directas del dataset son solo **igdb_rating** y las variables derivadas de conteo (**n_genres**, **n_platforms**, **n_developers**).

3.1 Coeficientes de Correlación de Pearson con el Rating

Variable	r de Pearson	Fuerza	Dirección
N° Generos	-0.1467	Débil	Negativa
N° Plataformas	-0.0968	Débil	Negativa
N° Desarrolladores	-0.0860	Débil	Negativa
Tiene Plataforma	-0.0687	Débil	Negativa

3.2 Heatmap de Correlación y Scatterplot




Figura 3: Heatmap de correlaciones y dispersión Rating vs N° Géneros.

Correlación espuria detectada:

La correlación entre **N° Desarrolladores** y **Tiene Plataforma** es técnicamente alta pero espuria: ambas variables están correlacionadas porque comparten la misma causa subyacente — la completitud del registro en IGDB. Un juego con datos de plataforma tiende a tener también datos de desarrolladores. Esta correlación no representa una relación causal real entre ambas variables.

■ En el rango elite del dataset (rating 93.8–100), ninguna variable disponible correlaciona significativamente con el rating ($|r| < 0.3$ en todos los casos). Esto indica que, dentro del top 150, la cantidad de géneros o plataformas no determina la calidad percibida de un juego.

4. Regresión Lineal — Lección 4

4.1 Regresión Lineal Simple

Se implementó una regresión lineal simple con `n_genres` como predictor de `igdb_rating`. La ecuación resultante es:

$$\text{Rating} = -0.2368 \times n_genres + 97.0911$$

Métrica	Regresión Simple	Regresión Múltiple
R ²	0.0215 (2.2%)	0.0309 (3.1%)
MSE	3.5251	3.4914
RMSE	1.8775	1.8685
MAE	1.6634	1.6519
Predictores	n_genres	n_genres, n_platforms, n_developers, tiene_plataforma

4.2 Visualización de la Regresión




Figura 4: Comparación real vs predicho y análisis de residuos.

El R^2 de ambos modelos es muy bajo (0.022 y 0.031 respectivamente), lo que confirma que las variables disponibles no son buenos predictores del rating en el rango estudiado. El análisis de residuos muestra dispersión aleatoria alrededor de cero, confirmando que no hay un patrón sistemático no capturado por el modelo — simplemente el rating en este rango no depende linealmente de las variables de estructura del juego.

5–6. Análisis Visual de Datos — Lecciones 5 y 6

5.1 Violinplot y Top Géneros




Figura 5: Distribución de rating por género (violinplot) y frecuencia de géneros.

El violinplot revela que géneros como **Adventure** y **Role-playing (RPG)** presentan distribuciones de rating similares, con medianas alrededor de 96–97. Los géneros **Indie** y **Platform** muestran mayor amplitud, sugiriendo mayor variabilidad interna en ese segmento.

7. Conclusiones y Recomendaciones

7.1 Hallazgos Principales

Dataset de élite: Los 150 juegos analizados representan el top mundial de IGDB, con ratings entre 93.8 y 100. Esta naturaleza élite explica la baja variabilidad y la ausencia de outliers.

Columna corrupta detectada: release_year no contiene años sino la primera palabra del nombre del juego — hallazgo crítico de IDA que invalida cualquier análisis temporal con el dataset actual.

Alta tasa de metadatos faltantes: Plataformas (38.7%) y desarrolladores (41.3%) sin datos registrados en IGDB limitan el alcance del análisis.

Correlaciones débiles: Ninguna variable disponible predice el rating con $r > 0.3$, confirmando que la excelencia de un juego es multifactorial y no capturada por variables estructurales simples.

Género dominante: Adventure (79 apariciones) y RPG (56) son los géneros más frecuentes en los juegos mejor valorados del mundo.

7.2 Recomendaciones Estratégicas

N°	Acción	Detalle
1	Regenerar la columna release_year desde la API de IGDB para habilitar análisis temporales de tendencias en la industria del game.	
2	Incorporar preprocesamiento de juegos: promedio, reseñas de usuarios, fecha de lanzamiento y número de reviews para mejorar el poder predictivo.	
3	Incluir juegos con rating de 92 y por debajo para estudiar qué diferencia a los mejores juegos del promedio y construir modelos con mayor capacidad.	
4	Completar el 40% de juegos sin datos de plataforma y desarrolladores representa una oportunidad de enriquecimiento via API IGDB.	
5	Profundizar análisis de diferencias de rating dentro de cada género para identificar oportunidades de negocio en segmentos específicos de nicho.	