



INFORME TÉCNICO DE ANÁLISIS EXPLORATORIO DE DATOS

Gaming Ratings Database — IGDB Top 150
Módulo 4: Análisis Exploratorio de Datos | Alkemy
Empresa: ComercioYA — Dirección de Análisis Estratégico
Fecha: 17 de febrero de 2026

RESUMEN DEL PROYECTO

Dataset	gaming-ratings-database-20260217.csv
Registros	150 juegos con rating IGDB
Variables	6 columnas originales (1 corrupta detectada)
Variable objetivo	igdb_rating (numérica continua, rango 93.8–100)
Herramientas	Python · Pandas · NumPy · Seaborn · Matplotlib · Scikit-learn
Metodología	EDA completo: IDA · Estadística · Correlación · Regresión · Viz

1. Análisis Inicial de Datos (IDA) — Lección 1

El dataset fue cargado desde el archivo CSV generado el 17 de febrero de 2026, conteniendo información de los 150 juegos mejor calificados en la plataforma IGDB (Internet Game Database). A continuación se detalla la estructura del dataset y los hallazgos del análisis inicial.

1.1 Estructura del Dataset

Variable	Tipo	Subtipo	Nulos	Observaciones
name	Categórica	Nominal	0 (0%)	Nombre del juego
slug	Categórica	Nominal	0 (0%)	ID URL único
igdb_rating	Numérica	Continua	0 (0%)	Rating 0–100
genres	Categórica	Lista	1 (0.7%)	Géneros
platforms	Categórica	Lista	58 (38.7%)	⚠ Alta tasa
developers	Categórica	Lista	62 (41.3%)	⚠ Alta tasa
release_year	—	—	—	🚫 Corrupta

💡 **HALLAZGO CRÍTICO** — `release_year`: La columna contiene la primera palabra del nombre de cada juego (ej: "Resonite", "Grand", "Metal") en lugar de un año numérico. Esto indica un error de generación del CSV. Esta columna fue excluida del análisis cuantitativo.

1.2 Tratamiento de Valores Faltantes

Las columnas **platforms** (38.7% nulos) y **developers** (41.3% nulos) presentan alta tasa de datos faltantes. Se decidió **no imputar** estos valores ya que la ausencia misma es informativa: indica que el juego no tiene metadatos completos registrados en IGDB.

2. Estadística Descriptiva — Lección 2

Se aplicaron las principales medidas de tendencia central y dispersión sobre la variable numérica principal `igdb_rating`.

2.1 Medidas Principales

Medida	Valor	Interpretación
Media (μ)	96.4927	Promedio del dataset
Mediana	96.0000	Valor central
Moda	94.0	Valor más frecuente
Desv. Estándar (σ)	1.9044	Dispersión baja
Varianza	3.6268	Cuadrado de σ
Mínimo	93.8	Rating mínimo
Máximo	100.0	Rating perfecto
Rango	6.2	Amplitud total
Q1 (25%)	94.90	Primer cuartil
Q3 (75%)	98.30	Tercer cuartil
IQR	3.40	Rango intercuartílico
Coef. Variación	1.97%	Variabilidad baja
Asimetría	0.1453	Casi simétrica
Curtosis	-0.9134	Aplanada

2.2 Detección de Outliers

Con $Q1=94.90$, $Q3=98.30$ e $IQR=3.40$, los límites son: **inferior=89.80** y **superior=103.40**. No se detectaron outliers en el dataset.

💡 La distribución es muy compacta ($\sigma=1.90$, $CV=1.97\%$). Todos los juegos son homogéneamente bien calificados, sin valores extremos.

3. Análisis de Correlación — Lección 3

Se calculó la matriz de correlación de Pearson entre todas las variables numéricas.

3.1 Coeficientes con el Rating

Variable	r de Pearson	Fuerza	Dirección
N° Géneros	+0.1071	Débil	Positiva
N° Plataformas	+0.0238	Débil	Positiva
N° Desarrolladores	-0.0449	Débil	Negativa
Tiene Plataforma	+0.0569	Débil	Positiva

Correlación espuria detectada:

La correlación entre **N° Desarrolladores** y **Tiene Plataforma** es técnicamente moderada pero espuria: ambas comparten la misma causa — completitud del registro en IGDB.

 **CONCLUSIÓN:** Ninguna variable correlaciona significativamente con el rating ($|r| < 0.3$). La cantidad de géneros o plataformas NO determina la calidad.

4. Regresión Lineal — Lección 4

4.1 Resultados de los Modelos

Se implementó regresión lineal simple (1 predictor) y múltiple (4 predictores).

Métrica	Reg. Simple	Reg. Múltiple
R²	0.0115 (1.1%)	0.0264 (2.6%)
MSE	3.6025	3.5471
RMSE	1.8980	1.8834
MAE	1.5076	1.4956

Ecuación simple: **Rating = 0.2040 × n_genres + 95.8439**

 El R² muy bajo (~0.01–0.03) confirma que las variables disponibles NO predicen el rating. El rating en este rango no depende de estructura del juego.

5. Conclusiones y Recomendaciones

5.1 Hallazgos Principales

- Dataset de élite: 150 juegos con ratings 93.8–100
- Columna corrupta: release_year no contiene años
- Alta tasa de nulos: 38.7% plataformas, 41.3% desarrolladores
- Correlaciones débiles: Ninguna variable predice rating ($r < 0.3$)
- Géneros dominantes: Adventure (79) y RPG (56)

5.2 Recomendaciones Estratégicas

N°	Acción	Detalle
1	Corregir dataset	Regenerar release_year desde API
2	Ampliar variables	Agregar precio, horas, reviews
3	Ampliar rango	Incluir juegos rating < 93
4	Completar datos	40% de juegos sin metadatos
5	Análisis género	Estudiar diferencias por segmento