

INFORME FINAL DE INVESTIGACIÓN

Análisis Estadístico sobre Hábitos Saludables en Jóvenes Universitarios

Módulo 5: Inferencia Estadística | Alkemy

Equipo de Investigación — Área de Salud Universitaria
n = 200 estudiantes universitarios | Año 2026

Resumen Ejecutivo

Este informe presenta los resultados de una investigación estadística sobre los hábitos de sueño, alimentación y actividad física en jóvenes universitarios. Se analizó una muestra simulada de $n=200$ estudiantes aplicando el método científico completo: desde la formulación de hipótesis hasta la realización de pruebas de significancia.

Los hallazgos más relevantes indican que los estudiantes duermen significativamente menos de 7 horas por noche ($\bar{x} \approx 6.17h$, $p < 0.001$), que el 45% no alcanza las 6 horas mínimas, y que quienes realizan actividad física regular muestran mejor calidad de sueño ($p=0.028$).

Lección 1: Método Científico y Estadística

1.1 Problema de Investigación

¿Cuáles son los patrones de sueño, alimentación y actividad física en jóvenes universitarios, y existe asociación entre estos hábitos y su rendimiento académico percibido?

1.2 Hipótesis

- H_0 (Nula): Los jóvenes universitarios duermen en promedio $\mu = 7$ horas por noche. No existe diferencia significativa entre quienes realizan actividad física y quienes no.
- H_1 (Alternativa): Los jóvenes universitarios duermen menos de 7 horas ($\mu < 7h$). Quienes realizan actividad física tienen mejor calidad de sueño.

1.3 Variables Identificadas

Tipo	Escala	Variables	Descripción
Cuantitativa continua	Razón	horas_sueno, horas_actividad, imc	Medibles con decimales, cero absoluto
Cuantitativa discreta	Razón	comidas_dia, dias_actividad, edad	Valores enteros contables
Cualitativa nominal	Nominal	genero, carrera, fuma, consume_alcohol	Categorías sin orden
Cualitativa ordinal	Ordinal	calidad_sueno, nivel_estres, rendimiento	Categorías con orden jerárquico

1.4 Enfoque Metodológico

- Tipo de estudio: Observacional, transversal y cuantitativo
- Método de muestreo: Estratificado por carrera (5 estratos) y género
- Tamaño muestral: $n = 200$ registros simulados con `numpy.random`
- Software: Python 3.x con NumPy, Pandas, SciPy, Matplotlib

Lección 2: Probabilidad y Muestreo

2.1 Tipo de Muestreo

Se utilizó muestreo estratificado, dividiendo la población por carrera (5 estratos: Exactas, Sociales, Salud, Tecnología, Humanidades) con proporciones representativas. Dentro de cada estrato, los estudiantes fueron seleccionados aleatoriamente.

2.2 Simulación del Dataset

El dataset fue generado con distribuciones estadísticas apropiadas para cada variable. La semilla aleatoria `np.random.seed(42)` garantiza reproducibilidad.

2.3 Probabilidades Calculadas

Evento	Fórmula	Resultado
P(duerme menos de 6 horas)	Frec. relativa	45.0%
P(activo ≥ 3 días/semana)	Frec. relativa	42.0%
P(poco sueño ∩ activo)	$P(A) \cdot P(B A)$	21.0%
P(poco sueño ∪ activo)	$P(A) + P(B) - P(A \cap B)$	66.0%
P(no activo) — complemento	$1 - P(\text{activo})$	58.0%
P(estrés alto sueño < 6h)	$P(A \cap B) / P(B)$	47.8%

Lección 3: Distribuciones de Probabilidad

3.1 Distribución Normal — Horas de Sueño

La variable horas de sueño, al ser continua y resultar de múltiples factores independientes, sigue una distribución Normal: $X \sim N(\mu=6.165, \sigma=1.248)$.

Evento	Fórmula	Probabilidad
$P(X < 6 \text{ horas})$	$\Phi((6-\mu)/\sigma)$	44.7%
$P(6 \leq X \leq 8 \text{ horas})$	$\Phi(8)-\Phi(6)$	48.2%
$P(X > 8 \text{ horas})$	$1 - \Phi((8-\mu)/\sigma)$	7.1%

3.2 Distribución Binomial — Actividad Física

En un grupo de 20 estudiantes, con probabilidad de éxito $p=0.42$ (activo ≥ 3 días/sem): $X \sim \text{Bin}(n=20, p=0.42)$.

- $P(X=10)$: probabilidad de exactamente 10 activos = 0.1359
- $P(X \geq 5)$: probabilidad de al menos 5 activos = 0.9651

3.3 Distribución Poisson — Comidas por Día

El número de comidas diarias sigue una distribución Poisson con $\lambda=3.22$ (media observada). Esta distribución modela eventos de conteo discretos.

- $P(X=3)$: 0.2223 — $P(X=2)$: 0.2071 — $P(X=4)$: 0.1790

Lección 4: Distribución Muestral y TLC

4.1 Teorema del Límite Central

El TLC establece que la distribución de la media muestral $\bar{X}$ se aproxima a una distribución Normal a medida que n aumenta, independientemente de la distribución original de la población.
Formalmente: $\bar{X} \sim N(\mu, \sigma^2/n)$.

4.2 Verificación Empírica (1000 muestras por tamaño)

n	σ empírico	$\sigma/\sqrt{n}$ teórico	Error %
5	0.5419	0.5567	2.67%
15	0.3062	0.3214	4.73%
30	0.2026	0.2273	10.84%
50	0.1530	0.1760	13.12%

Interpretación: Los resultados empíricos confirman el TLC. A mayor n , la dispersión de la media muestral se reduce según $\sigma/\sqrt{n}$, y la distribución de las medias se hace más Normal, como lo evidencian los gráficos generados.

Lección 5: Intervalos de Confianza

5.1 Metodología

Se utilizó la distribución t de Student (σ desconocido). Fórmula: $IC = \bar{x} \pm t(\alpha/2, n-1) \cdot (s/\sqrt{n})$

5.2 Resultados de Intervalos de Confianza

Variable	Nivel	Límite inferior	Límite superior	Ancho
Horas de sueño	90%	6.019	6.311	0.292
Horas de sueño	95%	5.991	6.339	0.348
Horas de sueño	99%	5.936	6.395	0.459
Actividad física (h)	95%	1.061	1.475	0.415
IMC	95%	23.009	24.365	1.355

5.3 Impacto del Tamaño Muestral (IC 95%, horas de sueño)

n	Ancho IC	Interpretación
20	1.3322	Muy amplio — estimación imprecisa
50	0.6491	Moderado
100	0.4691	Bueno
150	0.3836	Preciso
200	0.3480	Muy preciso — estimación confiable

Lección 6: Pruebas de Hipótesis

6.1 Resumen de los Tests Realizados

Test	H ₀	Estadístico	p-valor	Decisión
t unilateral	$\mu_{\text{sueño}} = 7\text{h}$	$t = -9.46$	$p < 0.001$	RECHAZAR H ₀ — duermen < 7h
ANOVA	Igualdad entre carreras	$F = 0.158$	$p = 0.959$	No rechazar H ₀
t independiente	Activos = Sedentarios	$t = 1.930$	$p = 0.028$	RECHAZAR H ₀ — activos mejor
z proporciones	$p_{\text{fuma}} = 20\%$	$z = -0.707$	$p = 0.760$	No rechazar H ₀

6.2 Errores Tipo I y Tipo II

Error Tipo I ($\alpha = 0.05$)

Definición: Rechazar H₀ cuando en realidad es verdadera (falso positivo). En este estudio, significaría concluir que los universitarios duermen menos de 7h cuando en realidad duermen 7h.

Consecuencia: Implementar políticas de salud del sueño innecesarias. Se aceptó un riesgo del 5%.

Error Tipo II ($\beta \approx 0.15$)

Definición: No rechazar H₀ cuando en realidad es falsa (falso negativo). Significaría no detectar que los estudiantes duermen menos de 7h cuando realmente lo hacen.

Consecuencia: No intervenir ante un problema real de salud estudiantil. Con $n=200$ y el efecto observado, la potencia estadística estimada es $1-\beta \approx 0.85$.

Conclusiones y Recomendaciones

7.1 Hallazgos Principales

#	Hallazgo	Evidencia estadística
1	Los universitarios duermen significativamente menos de 7h ($\bar{x} \approx 6.17h$)	$t = -9.46$, $p < 0.001$
2	El 45% no alcanza las 6h mínimas recomendadas	Probabilidad empírica
3	No hay diferencias de sueño entre carreras universitarias	ANOVA $F = 0.16$, $p = 0.96$
4	La actividad física mejora la calidad de sueño (activos: $\bar{x} = 3.04$ vs sedentarios: $\bar{x} = 2.72$)	$t = 1.93$, $p = 0.028$
5	El estrés alto se asocia con poco sueño (47.8% de quienes duermen $< 6h$)	Probabilidad condicional
6	Mayor n produce intervalos de confianza más precisos	IC 95%: $n = 20 \rightarrow 1.33$, $n = 200 \rightarrow 0.35$

7.2 Recomendaciones de Política Universitaria

- Implementar talleres de higiene del sueño al inicio de cada ciclo lectivo, con énfasis en el primer año.
- Promover la actividad física mediante programas de bienestar estudiantil, especialmente entre quienes reportan estrés alto.
- Ampliar el estudio a $n \geq 500$ en próximas mediciones para mayor potencia estadística ($\beta < 0.10$).
- Incorporar seguimiento longitudinal (mínimo 2 semestres) para establecer relaciones causales y no solo correlacionales.
- Evaluar intervenciones específicas para reducir el estrés académico, dado su asociación con la privación de sueño.
- Replicar el estudio con una muestra real (encuesta) para contrastar con los resultados simulados.

7.3 Limitaciones del Estudio

- Los datos son simulados, por lo que reflejan supuestos del investigador y no mediciones reales.
- El diseño transversal no permite establecer causalidad entre las variables.
- La autodeclaración de hábitos puede estar sujeta a sesgo de deseabilidad social.