

# ANÁLISIS DE CASO

Fundamentos del Aprendizaje de Máquina

---

**DataSolutions S.A.**

Área de Analítica Predictiva | Lección 1

Marzo 2026

# 1. Introducción y Contexto

DataSolutions S.A. es una empresa especializada en análisis predictivo de datos para clientes de los rubros de retail, banca y salud. Frente al crecimiento en el volumen y variedad de los datos disponibles, la dirección ha decidido implementar un proceso sistemático para seleccionar, diseñar y evaluar modelos de aprendizaje de máquina (ML).

El presente informe aborda tres problemas de negocio reales, aplicando los fundamentos del machine learning para determinar el tipo de tarea adecuada, el algoritmo más conveniente, los riesgos asociados y el flujo de trabajo para su implementación.

# 2. Clasificación de los Problemas

A continuación se presenta la clasificación de cada problema según el paradigma de aprendizaje de máquina correspondiente, seguida del detalle de cada caso.

| Problema | Descripción                           | Tipo de ML                  | Algoritmo                   | Supervisado |
|----------|---------------------------------------|-----------------------------|-----------------------------|-------------|
| A        | Predecir ventas semanales             | Regresión                   | Random Forest Regressor     | Sí          |
| B        | Detectar abandono de clientes (churn) | Clasificación Binaria       | Árbol de Decisión / XGBoost | Sí          |
| C        | Segmentar clientes bancarios          | Clustering (No Supervisado) | K-Means                     | No          |

## 2.1 Problema A — Regresión (Aprendizaje Supervisado)

**Enunciado:** Predecir el monto de ventas semanales de una cadena de supermercados.

Este problema requiere estimar un valor numérico continuo (monto en unidades monetarias) a partir de variables históricas y contextuales. Se trata de una tarea de regresión supervisada, ya que contamos con datos etiquetados (ventas históricas) que sirven como variable objetivo.

**Variables de entrada típicas:**

- **Históricas:** ventas de semanas anteriores, tendencia, estacionalidad.
- **Contextuales:** día festivo, promociones activas, clima, categoría de producto.
- **Externas:** indicadores económicos, competencia, eventos regionales.

## 2.2 Problema B — Clasificación Binaria (Aprendizaje Supervisado)

**Enunciado:** Detectar si un cliente abandonará un servicio de streaming (churn prediction).

El objetivo es predecir una categoría discreta: el cliente abandona el servicio (1) o no (0). Esto corresponde a una tarea de clasificación binaria supervisada. Se dispone de datos históricos con la etiqueta de si el cliente canceló o no.

**Variables de entrada típicas:**

- **Comportamiento:** frecuencia de uso, tiempo promedio de sesión, días sin actividad.
- **Perfil:** plan contratado, antigüedad, método de pago, dispositivos.
- **Interacciones:** contacto con soporte, quejas registradas, intentos de cancelación.

## 2.3 Problema C — Clustering (Aprendizaje No Supervisado)

**Enunciado:** Agrupar a los clientes bancarios por comportamiento de gasto sin tener etiquetas.

Dado que no existen etiquetas predefinidas para los grupos, este es un problema de aprendizaje no supervisado. El objetivo es descubrir estructuras ocultas en los datos mediante técnicas de clustering, identificando segmentos de clientes con comportamientos similares.

**Variables de entrada típicas:**

- **Transaccionales:** monto promedio de gastos, frecuencia de transacciones, categorías de gasto.
- **Patrimoniales:** saldo promedio en cuenta, productos financieros activos.
- **Demográficas:** edad, localidad, nivel de ingresos (si disponible).

## 3. Selección de Modelo y Justificación

### 3.1 Problema A — Random Forest Regressor

Se propone utilizar Random Forest Regressor como algoritmo principal. Este modelo ensemble construye múltiples árboles de decisión durante el entrenamiento y devuelve el promedio de sus predicciones para regresión.

#### Justificación de la elección

Las ventas de supermercados presentan relaciones no lineales (efecto de promociones, estacionalidad, feriados) que los modelos lineales simples capturan de forma deficiente. Random Forest maneja esta complejidad sin requerir transformaciones exhaustivas de las variables. Además, permite evaluar la importancia relativa de cada variable predictora, lo que aporta valor de negocio al equipo comercial.

#### Ventajas

- **Robustez:** resistente a outliers y datos ruidosos.
- **No lineal:** captura patrones complejos sin supuestos de linealidad.
- **Interpretabilidad parcial:** entrega importancia de variables (feature importance).
- **Bajo riesgo de overfitting:** gracias al promediado de múltiples árboles.
- **Sin necesidad de escalado:** no requiere normalización de variables numéricas.

#### Limitaciones

- **Costo computacional:** puede ser lento con datasets muy grandes y muchos árboles.
- **Interpretabilidad global:** menos interpretable que una regresión lineal simple.
- **Series temporales puras:** no modela dependencia temporal secuencial; requiere features de lag.

### 3.2 Problema B — Árbol de Decisión / XGBoost

Se propone un Árbol de Decisión como modelo base para su alta interpretabilidad (apto para explicar decisiones a clientes internos), y XGBoost (Gradient Boosting) como modelo de producción por su mayor rendimiento predictivo.

#### Justificación de la elección

El churn prediction implica un balance crítico entre precisión y recall: es más costoso no detectar a un cliente que va a abandonar (falso negativo) que alertar sobre uno que no lo hará. XGBoost optimiza este trade-off eficientemente, es robusto ante datos desbalanceados con el parámetro `scale_pos_weight`, y ofrece excelente rendimiento en datos tabulares.

## Ventajas

- **Alta precisión:** estado del arte para clasificación en datos tabulares.
- **Manejo de valores nulos:** XGBoost los maneja internamente.
- **Regularización:** L1 y L2 incorporadas para evitar overfitting.
- **Velocidad:** implementación optimizada y paralelizable.

## Limitaciones

- **Hiperparámetros:** requiere tuning cuidadoso (learning rate, max\_depth, n\_estimators).
- **Sesgo con clases desbalanceadas:** sin ajuste, el modelo puede ignorar la clase minoritaria.
- **Interpretabilidad:** menos transparente que un árbol simple; requiere SHAP values para explicar.

## 3.3 Problema C — K-Means

Se propone K-Means como algoritmo de clustering. Este método particiona los datos en K grupos, minimizando la inercia intra-cluster (suma de distancias al centroide de cada grupo).

### Justificación de la elección

K-Means es el estándar de la industria para segmentación de clientes por su eficiencia computacional y la facilidad de interpretar los centroides resultantes como perfiles de cliente. Los segmentos obtenidos (ej. cliente ahorrista, gastador frecuente, deudor recurrente) son directamente accionables por el equipo de marketing bancario.

## Ventajas

- **Escalabilidad:** eficiente con grandes volúmenes de datos.
- **Simplicidad:** fácil de implementar e interpretar los resultados.
- **Centroides como perfiles:** los centroides de cada cluster son perfiles de cliente directamente utilizables.

## Limitaciones

- **K debe definirse a priori:** requiere el método del codo o Silhouette Score para elegir K óptimo.
- **Sensible a outliers:** un cliente atípico puede distorsionar un centroide.
- **Asume clusters esféricos:** no captura bien grupos de formas irregulares.
- **Sensible a escala:** requiere normalización de variables (StandardScaler o MinMaxScaler).

## 4. Identificación de Riesgos y Desafíos

### 4.1 Problema A — Predicción de Ventas

- **Overfitting por granularidad:** si el modelo se entrena con demasiados features muy específicos (ej. ID de tienda sin generalizar), puede memorizar patrones históricos sin capacidad de generalizar a nuevas semanas.
- **Data leakage (fuga de datos):** incluir variables que implícitamente contengan la respuesta (ej. ingresos de caja del mismo día) contamina el modelo y genera métricas artificialmente buenas.
- **Dependencia temporal:** una división train/test aleatoria ignoraría la estructura temporal. Se debe usar validación temporal (time-series split).
- **Eventos excepcionales:** picos de ventas por pandemia, desastres naturales o inflación extrema generan distribuciones que el modelo entrenado en datos normales no puede predecir.
- **Variables categóricas de alta cardinalidad:** el ID de producto con miles de SKUs requiere encoding cuidadoso (target encoding, embeddings).

### 4.2 Problema B — Detección de Churn

- **Clases desbalanceadas:** en streaming, el porcentaje de churners suele ser del 5-20%. Un clasificador naive que prediga siempre 'no abandona' obtendría 90%+ de accuracy sin ningún valor real.
- **Concepto drift:** los patrones de comportamiento del cliente cambian con el tiempo (nuevas funcionalidades, competidores). El modelo debe ser re-entrenado periódicamente.
- **Sesgo por selección:** si los datos históricos fueron influenciados por campañas de retención, el churn 'real' está subestimado en el dataset.
- **Maldición de la dimensionalidad:** al incluir muchas variables de comportamiento, el espacio de características se vuelve disperso y las distancias pierden significado. Se requiere selección o reducción de features.
- **Umbral de decisión:** el threshold por defecto de 0.5 puede no ser óptimo. Debe ajustarse según el costo relativo de falsos positivos vs falsos negativos (análisis costo-beneficio).

### 4.3 Problema C — Segmentación de Clientes

- **Elección de K:** seleccionar un K incorrecto produce segmentos sin sentido de negocio. El método del codo y el Silhouette Score deben combinarse con criterio experto.
- **Outliers distorsionantes:** clientes con comportamientos extremos (fraude, errores de carga) pueden atraer centroides hacia valores no representativos.
- **Variables en diferentes escalas:** mezclar montos de transacción (miles de pesos) con frecuencia (1-30 veces/mes) sin normalizar hace que K-Means priorice las variables de mayor magnitud.

- **Estabilidad de clusters:** K-Means tiene inicialización aleatoria. Diferentes runs pueden producir particiones distintas. Usar K-Means++ y múltiples inicializaciones mitiga este problema.
- **Interpretación sin etiquetas:** los clusters no tienen nombres automáticos. Se requiere análisis post-hoc con el equipo de negocio para dotar de significado a cada segmento.

## 5. Diseño del Flujo de Trabajo — Caso B: Detección de Churn

Se presenta el flujo de trabajo completo para el Problema B (detección de abandono en streaming), que representa el caso de mayor impacto operativo inmediato para DataSolutions S.A.

| Etapa | Actividad Principal                | Detalle / Acciones                                                                                                                                | Herramientas (Python)                       |
|-------|------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------|
| 1     | <b>Definición del Problema</b>     | Establecer la variable objetivo (churn: 0/1), horizonte de predicción (ej. 30 días), costo de falso negativo vs positivo, y KPIs de éxito.        | <i>Reuniones con negocio, documentación</i> |
| 2     | <b>Recopilación de Datos</b>       | Extraer datos de plataforma de streaming: logs de uso, historial de pagos, datos de perfil, historial de contacto con soporte.                    | <i>SQL, APIs, pandas</i>                    |
| 3     | <b>Análisis Exploratorio (EDA)</b> | Distribución de clases (churn rate), correlaciones, detección de outliers, análisis de valores nulos, visualización de patrones temporales.       | <i>pandas, matplotlib, seaborn</i>          |
| 4     | <b>Preparación de Datos</b>        | Imputación de nulos, encoding de variables categóricas, ingeniería de features (días sin login, ratio de uso), normalización, balanceo con SMOTE. | <i>scikit-learn, imbalanced-learn</i>       |
| 5     | <b>División Train/Test</b>         | Split temporal: datos hasta N-30 días para entrenamiento, últimos 30 días para test. Evitar data leakage.                                         | <i>scikit-learn TimeSeriesSplit</i>         |
| 6     | <b>Selección y Entrenamiento</b>   | Entrenar Árbol de Decisión (baseline) y XGBoost (producción). Optimizar hiperparámetros con GridSearchCV o Optuna.                                | <i>scikit-learn, XGBoost, Optuna</i>        |
| 7     | <b>Evaluación del Modelo</b>       | Calcular F1-Score, Recall, AUC-ROC en set de test. Análisis de curva ROC, matriz de confusión, análisis de umbrales.                              | <i>scikit-learn metrics, matplotlib</i>     |
| 8     | <b>Interpretabilidad</b>           | Calcular SHAP values para explicar predicciones individuales. Revisar feature importance global. Validar con equipo de negocio.                   | <i>shap, eli5</i>                           |
| 9     | <b>Despliegue</b>                  | Empaquetar modelo con MLflow o joblib. Exponer via API REST (FastAPI). Monitorear drift con Evidently AI.                                         | <i>MLflow, FastAPI, Evidently AI</i>        |
| 10    | <b>Monitoreo y Reentrenamiento</b> | Monitorear métricas en producción semanalmente. Programar reentrenamiento automático mensual o ante caída de performance.                         | <i>MLflow, Airflow, Great Expectations</i>  |



## 6. Propuesta de Métricas de Evaluación

La siguiente tabla resume las métricas clave para evaluar el desempeño de cada modelo, con la justificación de su elección en el contexto de negocio de DataSolutions S.A.

| Caso | Métricas Primarias                                        | Justificación                                                                                                                                | Métricas Secundarias                          |
|------|-----------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------|
| A    | RMSE, MAE, R <sup>2</sup> (coeficiente de determinación)  | El RMSE penaliza errores grandes, crítico en predicción de ventas. El R <sup>2</sup> indica qué porcentaje de la varianza explica el modelo. | MAPE (error porcentual), Feature Importance   |
| B    | F1-Score, Recall, AUC-ROC                                 | Con clases desbalanceadas, el Recall es clave para no perder verdaderos churns. El AUC-ROC evalúa la discriminación global del modelo.       | Matriz de confusión, Precision                |
| C    | Inercia (Within-Cluster Sum of Squares), Silhouette Score | El Silhouette Score mide qué tan bien separados están los clusters. El método del codo con inercia ayuda a determinar K óptimo.              | Davies-Bouldin Index, visualización PCA/t-SNE |

## 7. Reflexión Personal

El desarrollo de este análisis de caso permite conectar los conceptos teóricos del aprendizaje de máquina con situaciones de negocio concretas. Una de las principales conclusiones es que la elección del algoritmo correcto no depende únicamente del rendimiento técnico, sino también de la interpretabilidad requerida por los stakeholders, el costo de los errores (falsos positivos vs negativos) y la disponibilidad de datos etiquetados.

En el Problema A, la naturaleza continua y temporal de las ventas exige no solo un buen modelo sino una estrategia de validación temporal que respete la causalidad de los datos. En el Problema B, el verdadero desafío no es el algoritmo sino el desbalanceo de clases y la definición del umbral correcto según el análisis costo-beneficio del negocio. En el Problema C, la ausencia de etiquetas obliga a una validación más cualitativa, involucrando activamente al equipo de negocio para validar que los segmentos obtenidos tienen sentido estratégico.

Finalmente, el flujo de trabajo diseñado para el Problema B deja en evidencia que el modelado representa apenas una fracción del trabajo total: la preparación de datos, la interpretabilidad y el monitoreo en producción consumen la mayor parte del tiempo y son determinantes para el éxito real de un proyecto de ML en producción.