

INFORME DE PREPROCESAMIENTO Y ESCALAMIENTO DE DATOS

RetailData Analytics | Especialista en Preparación de Datos | Lección 3 | Marzo 2026

1. Etapas del Preprocesamiento Aplicadas

Etapa	Técnica Aplicada	Descripción y Resultado
1	Imputación de nulos	La columna Ingresos tenía 1 valor nulo (ID=3). Se reemplazó con la media del resto de valores: $(30.000 + 50.000 + 40.000) / 3 = \40.000 . Se utilizó SimpleImputer(strategy='mean') de scikit-learn.
2	Label Encoding	La columna Ciudad fue codificada numéricamente con LabelEncoder: Barcelona→0, Madrid→1, Sevilla→2. Útil para algoritmos que acepten ordinales, aunque introduce orden artificial.
3	One-Hot Encoding	Se generaron 3 columnas binarias (Ciudad_Barcelona, Ciudad_Madrid, Ciudad_Sevilla) mediante pd.get_dummies(). Cada columna contiene 1 si el cliente pertenece a esa ciudad, 0 en caso contrario.
4	Variables Dummy	Similar al One-Hot pero con drop_first=True para eliminar Barcelona como categoría de referencia, evitando la trampa de la multicolinealidad (dummy variable trap).
5	Normalización Min-Max	Edad e Ingresos escalados al rango [0,1] con fórmula $x' = (x - \min) / (\max - \min)$. Resultados: Edad {0.0, 1.0, 0.25, 0.75}, Ingresos {0.0, 1.0, 0.5, 0.5}.
6	Estandarización Z-Score	Edad e Ingresos transformados a media=0, std=1 con $z = (x - \mu) / \sigma$. Valores negativos indican estar por debajo de la media; positivos, por encima.

2. Respuestas a las Preguntas de Reflexión

¿Por qué es importante el preprocesamiento antes de entrenar un modelo de ML?





Los algoritmos de ML no toleran valores nulos (producen errores o predicciones incorrectas) ni variables categóricas en texto (requieren representación numérica). Además, modelos sensibles a la distancia como K-Means, KNN o regresión logística asignan mayor peso a las variables de mayor magnitud si no se escalan. El preprocesamiento garantiza datos coherentes, completos y comparables, lo que se traduce directamente en mayor calidad y generalización del modelo entrenado.

¿Qué diferencias se observaron entre normalización y estandarización?

Aspecto	Normalización Min-Max	Estandarización Z-Score
Rango resultante	Siempre [0, 1]	Sin límite fijo (típicamente -3 a +3)
Fórmula	$x' = (x - \min) / (\max - \min)$	$z = (x - \mu) / \sigma$
Sensibilidad outliers	Alta (un outlier distorsiona min/max)	Moderada (afecta μ y σ)
Cuándo usarla	Redes neuronales, KNN, K-Means	Regresión, SVM, PCA
Edad — ID=1 (25)	0.0	-1.2649
Ingresos — ID=2	1.0	+1.4142

3. Visualización de Datos Escalados

Visualización de Datos Escalados — RetailData Analytics



Los gráficos superiores comparan valores originales con Min-Max [0,1]. Los inferiores muestran los Z-Scores, donde 0 representa la media del grupo.