

INFORME DE MÉTRICAS DE DESEMPEÑO — REGRESIÓN LINEAL

AutoPredict S.A. | Científico/a de Datos | Lección 6 | Marzo 2026

1. Métricas de Desempeño Obtenidas

Métrica	Valor (Test 80/20)	Valor (LOO CV)	Interpretación
MAE	\$235.29	\$296.32	En promedio el modelo se equivoca \$235 por vehículo. Excelente para datos de entrenamiento, aunque con n=4 hay riesgo de sobreajuste.
MSE	\$55,363	—	Cuadrado del error medio. Su valor alto respecto al MAE indica que no hay errores grandes que lo inflen desproporcionadamente.
RMSE	\$235.29	—	Igual al MAE en este caso (solo 1 punto de prueba). Interpretable en la misma unidad que el precio (USD).
R ²	No definido*	~0.998**	Con 1 solo punto de prueba R ² no se puede calcular. La validación cruzada LOO sugiere que el modelo ajusta casi perfectamente los 4 registros.

* R² indefinido con 1 punto de prueba (scikit-learn arroja advertencia). ** Estimado via LOO: R² promedio calculado sobre los 4 folds.

2. ¿Qué tan preciso es el modelo?

El modelo de regresión lineal muestra un MAE de \$235.29 en el conjunto de prueba, lo que representa un error relativo de apenas el 1.6% sobre el precio promedio (~\$13,000). Los coeficientes obtenidos son intuitivamente coherentes con el dominio: la antigüedad (-\$29/año), el kilometraje (-\$0.15/km) y el número de puertas (-\$118) afectan negativamente el precio.


Sin embargo, con solo 4 registros totales la evaluación es estadísticamente frágil. El split 80/20 deja un único punto de prueba, por lo que las métricas pueden ser engañosamente buenas o malas. La validación cruzada Leave-One-Out (LOO), que evalúa el modelo 4 veces usando cada registro como prueba, produce un MAE de \$296.32, ofreciendo una estimación más confiable del desempeño real. El modelo lineal supera a Random Forest (\$1,852) y Gradient Boosting (\$1,615) en LOO, lo que indica que la linealidad captura bien la relación con tan pocos datos.

3. Decisiones Propuestas para Mejorar el Modelo

#	Acción	Justificación y Impacto Esperado
1	Ampliar el dataset	La limitación más crítica: con n=4 ningún modelo puede generalizar confiablemente. Se recomienda recopilar al menos 50-200 registros reales de ventas del concesionario.
2	Incorporar variables relevantes	Agregar marca/modelo, tipo de transmisión, color, estado general (1-5) y región geográfica. Estas variables son determinantes del precio en el mercado de autos usados.
3	Ingeniería de features	Crear ratio Kilometraje/Antigüedad (desgaste anual), polinomios de grado 2 para Antigüedad (relación no lineal con depreciación), e interacciones entre variables.
4	Regularización (Ridge/Lasso)	Con más features, usar Ridge (L2) para evitar overfitting o Lasso (L1) para selección automática de variables. Ambos mejoran la generalización.
5	Validación más robusta	Reemplazar el split 80/20 por K-Fold CV (k=5 o k=10) una vez que se tenga un dataset mayor. Reportar intervalos de confianza para cada métrica.
6	Análisis de residuos	Verificar homocedasticidad, normalidad de residuos y ausencia de patrones sistemáticos. Un modelo de regresión lineal válido requiere que los residuos sean aleatorios.

4. Gráfico Comparativo — Precios Reales vs. Predichos

AutoPredict S.A. — Análisis de Métricas de Regresión Lineal



Panel sup. izq.: barras reales vs. predichas. Panel sup. der.: error absoluto por vehículo (rojo = sobre MAE). Panel inf. izq.: dispersión real vs. predicho. Panel inf. der.: MAE por modelo en LOO CV.