



# INFORME FINAL

## Predicción Inteligente de Gasto en Clientes E-commerce

Módulo 6: Aprendizaje de Máquina Supervisado | Alkemy

Marzo 2026

## 1. Resumen Ejecutivo

Se desarrolló un modelo de regresión supervisada para predecir el monto promedio de compra de clientes en una plataforma e-commerce. A partir de un dataset de 1.000 registros con 15 variables de comportamiento y demografía, se entrenaron y compararon 6 algoritmos.

El modelo final seleccionado fue el **Gradient Boosting Regressor**, que alcanzó un  **$R^2 = 0.7956$** , un **MAE = \$20.70** y un **RMSE = \$26.08** en el conjunto de prueba.

## 2. Definición del Problema

| Atributo           | Detalle                                                            |
|--------------------|--------------------------------------------------------------------|
| Tipo de problema   | Regresión supervisada                                              |
| Variable objetivo  | monto_compra_promedio (continua, USD)                              |
| Unidad solicitante | Departamento de Analítica Comercial                                |
| Contexto           | Personalizar ofertas según el perfil de gasto esperado del cliente |

## 3. Descripción del Dataset

| Atributo                            | Valor                                                                 |
|-------------------------------------|-----------------------------------------------------------------------|
| Registros                           | 1.000 clientes simulados                                              |
| Total de variables                  | 16 (15 features + 1 target)                                           |
| Variables categóricas               | 5 (genero, region, dispositivo, categoria_preferida, nivel_membresia) |
| Variables numéricas                 | 10                                                                    |
| Valores nulos (antes de imputación) | 90 (~3%)                                                              |
| Outliers eliminados en target       | 2                                                                     |

## 4. Preprocesamiento

### 4.1 Tratamiento de Valores Nulos

Se aplicó imputación por mediana en las columnas con valores faltantes:

- tiempo\_promedio\_sesion\_min
- calificacion\_promedio\_dada
- dias\_desde\_ultima\_compra

### 4.2 Outliers

Se utilizó el método IQR (Rango Intercuartílico) sobre la variable objetivo monto\_compra\_promedio, eliminando 2 registros extremos.

### 4.3 Codificación y Escalamiento

- Codificación: Label Encoding para variables categóricas (genero, region, dispositivo, categoria\_preferida, nivel\_membresia).
- Escalamiento: StandardScaler (media = 0, desvío estándar = 1) sobre el conjunto de entrenamiento, aplicado al de prueba sin re-ajuste.
- División: 80% entrenamiento / 20% prueba (random\_state=42).

## 5. Modelos Entrenados y Resultados

| Modelo                                                                                                | MAE (\$) | RMSE (\$) | R <sup>2</sup> |
|-------------------------------------------------------------------------------------------------------|----------|-----------|----------------|
| Regresión Lineal                                                                                      | 22.15    | 28.15     | 0.7618         |
| Regresión Polinomial (g=2)                                                                            | 25.60    | 31.12     | 0.7090         |
| KNN Regressor (k=7)                                                                                   | 30.64    | 37.94     | 0.5674         |
| Ridge (alpha=10)                                                                                      | 22.09    | 28.12     | 0.7624         |
| Lasso (alpha=0.1)                                                                                     | 22.11    | 28.13     | 0.7622         |
| Gradient Boosting  | 20.70    | 26.08     | 0.7956         |

Nota: R<sup>2</sup> mide la proporción de varianza explicada (mayor = mejor). MAE y RMSE expresan el error en dólares (menor = mejor).

### 5.1 Validación Cruzada K-Folds (k=5)

| Modelo           | CV R <sup>2</sup> (media ± desvío) |
|------------------|------------------------------------|
| Regresión Lineal | 0.7002 ± 0.0545                    |
| KNN Regressor    | 0.4467 ± 0.0321                    |

## 6. Modelo Final: Gradient Boosting Regressor

### 6.1 Hiperparámetros Óptimos (GridSearchCV)

| Hiperparámetro | Valor Óptimo |
|----------------|--------------|
| n_estimators   | 200          |
| learning_rate  | 0.10         |
| max_depth      | 3            |

## 6.2 Variables Más Importantes

- nivel\_membresia — clientes Platino gastan ~\$90 más que Bronce
- items\_en\_carrito — cada ítem adicional suma ~\$12 al monto
- paginas\_vistas\_sesion — refleja intención de compra
- tiempo\_promedio\_sesion\_min — mayor tiempo = mayor engagement
- frecuencia\_visitas\_mes — clientes recurrentes compran más

## 7. Análisis de Residuos

Los residuos del modelo Gradient Boosting presentan distribución aproximadamente normal centrada en 0, indicando buen ajuste sin sesgo sistemático. No se observan patrones heterocedásticos relevantes, lo que valida la confiabilidad del modelo.

## 8. Conclusiones

- El problema es de regresión supervisada: la variable objetivo es continua; usar clasificación implicaría pérdida de información y precisión.
- Gradient Boosting supera a la regresión lineal en  $R^2$  (+3.4 p.p.) y MAE (-\$1.45), justificando su elección como modelo final.
- La regularización (Ridge/Lasso) no mejoró significativamente respecto a la regresión lineal base, indicando baja multicolinealidad en el dataset.
- KNN Regressor tuvo el peor desempeño, confirmando la sensibilidad de este algoritmo a la alta dimensionalidad.
- Las variables de comportamiento en el sitio y el nivel de membresía son los predictores más potentes del gasto esperado.

## 9. Recomendaciones

| # | Recomendación                                                          | Impacto |
|---|------------------------------------------------------------------------|---------|
| 1 | Probar XGBoost o LightGBM como alternativas de boosting más eficientes | Alto    |
| 2 | Incorporar datos reales de transacciones con más meses de historial    | Alto    |

| # | Recomendación                                                                | Impacto |
|---|------------------------------------------------------------------------------|---------|
| 3 | Aplicar One-Hot Encoding para variables nominales (en vez de Label Encoding) | Medio   |
| 4 | Explorar ingeniería de features: ratio gasto/visitas, métricas RFM           | Medio   |
| 5 | Monitorear el modelo en producción con métricas en ventana deslizante        | Alto    |
| 6 | Segmentar por cluster de clientes y entrenar modelos específicos por grupo   | Medio   |
| 7 | Reentrenar el modelo mensualmente con nuevas transacciones                   | Alto    |

## 10. Valor para el Negocio

Con un error promedio de \$20.70 por predicción, el modelo permite:

- Personalizar descuentos y cupones según el perfil de gasto esperado por cliente.
- Priorizar clientes con alto potencial de compra en campañas de marketing paid.
- Detectar clientes en riesgo de churn: alta inactividad combinada con predicción de gasto bajo.
- Optimizar el inventory planning anticipando demanda por segmento de clientes.