

Informe: Reducción Dimensional

VisionData | Especialista en Ciencia de Datos | Dataset: survey_data.csv (500 clientes × 60 variables)

Técnica Recomendada: PCA para Presentaciones Ejecutivas

Para presentar insights al equipo de marketing y ventas, se recomienda PCA como técnica principal. Si bien t-SNE genera clusters visualmente más compactos y separados, PCA presenta ventajas decisivas en este contexto:

- Los ejes son interpretables: PC1 y PC2 tienen carga sobre variables concretas del dataset (demográficas, consumo, digitales), lo que permite explicar *por qué* los segmentos difieren.
- Es reproducible y estable: dos corridas con los mismos datos producen exactamente el mismo resultado, requisito para reportes ejecutivos periódicos.
- Permite proyectar nuevos clientes sobre los mismos ejes sin reentrenar el modelo.
- Los 2 primeros componentes capturan el **69.8% de la varianza total** del dataset, suficiente para identificar los cuatro segmentos con claridad.

Principales Hallazgos

El análisis identificó 4 agrupamientos naturales de clientes en el espacio reducido:

Segmento	Perfil
Jóvenes digitales	Alto score en variables demográficas de edad joven y preferencias digitales.
Adultos conservadores	Patrón bajo en demo, moderado consumo, neutral en digital.
Seniors offline	Fuerte en preferencias digitales básicas, bajo consumo online.
Profesionales tech	Alto consumo, bajo en indicadores digitales avanzados.

Ambas técnicas confirman la separación de los segmentos. t-SNE los muestra más compactos y separados, pero sin interpretabilidad de los ejes.

Reflexión Crítica

La reducción dimensional es poderosa pero conlleva pérdida de información: con PCA 2D se descarta el 30.2% de la varianza. Para modelos predictivos, sería preferible conservar más componentes (10 PCs capturan el 76.4%).

t-SNE no debe usarse para más que visualización exploratoria: sus distancias entre clusters no son comparables entre ejecuciones y escala mal con millones de registros.

Estrategia recomendada para grandes volúmenes

Para conjuntos de datos mucho mayores, la estrategia recomendada es:

- PCA incremental (IncrementalPCA) o TruncatedSVD para datos sparse.

- UMAP como alternativa a t-SNE: más rápido, con mejor preservación de estructura global y soporte para proyección de nuevos puntos.
- Pipeline sugerido: PCA incremental → UMAP para la proyección 2D final.