

SEGMENTADOR INTELIGENTE DE CLIENTES MINORISTAS

Informe Final de Resultados y Recomendaciones

Retail Insights S.A.

Departamento de Inteligencia de Negocios

Módulo 7: Aprendizaje No Supervisado

Marzo 2026

1. Resumen Ejecutivo

Se desarrolló un sistema de segmentación de clientes para Retail Insights S.A. usando técnicas de Machine Learning no supervisado sobre un dataset de 8.068 clientes. Tras preprocesamiento riguroso, se aplicaron algoritmos de reducción dimensional (PCA y t-SNE) y tres algoritmos de clusterización (K-Means, DBSCAN y Agrupamiento Jerárquico), identificando 4 segmentos de comportamiento claramente diferenciados.

El modelo K-Means con k=4 fue seleccionado como modelo final por su balance entre interpretabilidad y calidad métrica (coeficiente de silueta = 0.168), alineado además con las 4 categorías de segmentación presentes en el dataset original.

Resumen de Métricas Clave	
Registros procesados	6.969
Features utilizadas	9
Algoritmo seleccionado	K-Means (k=4)
Coeficiente de Silueta (K-Means)	0.1680
Coeficiente de Silueta (Jerárquico)	0.1285
Coeficiente de Silueta (DBSCAN)	0.1085
Varianza PCA explicada (2 comp.)	41.45%

2. Contexto y Objetivo

2.1 Situación Inicial

Retail Insights S.A. asesora a cadenas de retail que actualmente utilizan segmentación básica (edad, compras totales) para sus campañas de marketing. Esta aproximación no permite identificar patrones ocultos de comportamiento ni diseñar estrategias diferenciadas para grupos con necesidades distintas.

2.2 Objetivo del Proyecto

Desarrollar un sistema de segmentación no supervisado que:

- Identifique grupos de clientes con comportamiento homogéneo internamente y heterogéneo entre sí.
- Sea visualizable y comunicable a equipos de negocio no técnicos.
- Pueda extenderse a nuevos datos de forma escalable.
- Genere recomendaciones accionables para campañas de marketing, retención y fidelización.

3. Datos y Preprocesamiento

3.1 Descripción del Dataset

El dataset contiene 8.068 registros de clientes con las siguientes variables:

Variable	Tipo	Descripción
Age	Numérica	Edad del cliente (18-89 años)
Gender	Categórica	Género: Male / Female
Ever_Married	Binaria	Estado civil: Yes / No
Graduated	Binaria	Nivel educativo: Yes / No
Profession	Categórica	Profesión (Healthcare, Engineer, Lawyer, etc.)
Work_Experience	Numérica	Años de experiencia laboral (0-14)
Spending_Score	Ordinal	Nivel de gasto: Low / Average / High
Family_Size	Numérica	Tamaño del grupo familiar (1-9)
Var_1	Categórica	Variable categórica anónima (Cat_1 a Cat_7)

3.2 Pasos de Preprocesamiento

- Eliminación de columna ID (no aporta información de comportamiento).
- Imputación de valores nulos: mediana para numéricas (Work_Experience, Family_Size) y moda para categóricas.
- Encoding ordinal con sentido semántico (Spending_Score: Low=0, Average=1, High=2).
- Label Encoding para Profession y Var_1.
- Eliminación de outliers extremos (IQR x3) en variables numéricas: de 8.068 a 6.969 registros.
- Normalización con StandardScaler (media=0, desviación=1) para garantizar que todas las features contribuyan por igual.

4. Reducción Dimensional

4.1 PCA — Análisis de Componentes Principales

PCA fue aplicado sobre las 9 features normalizadas. Las dos primeras componentes explican el 41.45% de la varianza total (PC1=25.45%, PC2=16.00%), lo cual es esperable en datos con variables de naturaleza muy diversa (demográficas, conductuales y categóricas).




Figura 1: Varianza explicada por componentes PCA

4.2 t-SNE — Reducción No Lineal

t-SNE (perplexity=40) fue aplicado para capturar relaciones no lineales entre clientes. A diferencia de PCA, t-SNE preserva la estructura local de los datos, lo que resulta más útil para visualizar clústeres compactos y separados.




Figura 2: Comparación visual PCA vs t-SNE coloreados por segmentación original

4.3 Comparativa y Justificación

Para visualización de clústeres en este proyecto se utilizó PCA como reducción intermedia (por velocidad y reproducibilidad) y t-SNE como visualización final (por su capacidad de revelar grupos compactos). Ambas técnicas son complementarias:

- PCA: mejor para análisis de importancia de variables y como paso previo a modelos.
- t-SNE: mejor para visualización exploratoria y comunicación de resultados a stakeholders.

5. Algoritmos de Clusterización

5.1 Determinación del K Óptimo

Se utilizaron el Método del Codo y el Coeficiente de Silueta para determinar el número óptimo de clústeres. El codo sugiere $k=5$, mientras que la silueta máxima se alcanza en $k=2$. Se eligió $k=4$ por su coherencia con el negocio (4 segmentaciones conocidas en el dataset).




Figura 3: Método del Codo y Coeficiente de Silueta para $k=2..10$

5.2 K-Means

K-Means con $k=4$ produjo los mejores resultados (silueta=0.168). El algoritmo converge a centroides estables y produce segmentos de tamaño relativamente balanceado, lo que facilita la planificación de campañas.

5.3 DBSCAN

DBSCAN identificó 35 micro-clústeres con 340 puntos clasificados como ruido (4.9% del total). Si bien detecta patrones no esféricos, en este dataset con alta dimensionalidad y variables mixtas no logra una separación nítida comparable a K-Means. Su principal aporte es la detección de outliers.

5.4 Agrupamiento Jerárquico (Ward)

El agrupamiento jerárquico con enlace Ward y $k=4$ produce resultados intermedios (silueta=0.1285). Su principal valor es el dendrograma, que permite visualizar cómo los clústeres se forman progresivamente y en qué punto cortar para obtener k grupos.




Figura 4: Dendrograma Ward (muestra n=500 clientes)

6. Resultados Visuales




Figura 5: Clústeres proyectados en PCA — K-Means, DBSCAN y Jerárquico




Figura 6: Clústeres proyectados en t-SNE — K-Means, DBSCAN y Jerárquico




Figura 7: Comparativa de coeficiente de silueta entre los tres algoritmos

7. Perfil de los Segmentos (K-Means)




Figura 8: Heatmap de características por clúster (valores Z)




Figura 9: Distribuciones clave por clúster

Clúster	n	Edad media	Exp. Laboral	Tamaño familia	Gasto predominante
0	944	70.2	1.25	2.20	Average
1	2.950	46.8	2.45	2.85	Low-Average
2	1.561	26.9	2.25	4.15	Low
3	1.514	37.4	4.24	1.88	Variable

8. Conclusiones

8.1 Segmento 0 — Adultos Mayores Estables

Clientes de mayor edad (70 años en promedio), con experiencia laboral reducida (posiblemente jubilados) y familias pequeñas. Gasto predominantemente promedio. Estrategia sugerida: programas de fidelización con beneficios en salud, comodidades y delivery. Campañas de retención basadas en confianza y servicio.

8.2 Segmento 1 — Adultos Maduros Familiares

El segmento más numeroso (2.950 clientes). Edad media de 47 años, familias de tamaño medio. Gasto entre bajo y promedio. Son el core del negocio. Estrategia sugerida: programas de valor por volumen, descuentos por compra familiar, membresías. Campañas de cross-selling y up-selling.

8.3 Segmento 2 — Jóvenes con Familia Grande

Clientes jóvenes (27 años en promedio) con familias numerosas (4.15 miembros) y gasto bajo. Potencial de crecimiento alto. Estrategia sugerida: promociones de primer impacto, programas de ahorro, bundles familiares. Captura temprana para convertirlos en clientes de largo plazo.

8.4 Segmento 3 — Profesionales Independientes

Clientes de 37 años con alta experiencia laboral (4.24 años de media) y familias pequeñas (1.88). Gasto variable. Estrategia sugerida: productos premium, servicios de conveniencia, suscripciones. Campañas enfocadas en ahorro de tiempo y calidad.

9. Recomendaciones Accionables

9.1 Aplicaciones de Marketing

- Diseñar 4 plantillas de campaña diferenciadas, una por segmento.
- Priorizar el Segmento 2 (jóvenes con familia grande) para programas de captación temprana.
- Implementar retención premium para el Segmento 0 (adultos mayores) dada su estabilidad.
- Explorar ventas cruzadas en el Segmento 3 (profesionales) con productos de conveniencia y calidad.

9.2 Mejoras Técnicas Futuras

- Incorporar datos de comportamiento de compra en el tiempo (RFM: Recencia, Frecuencia, Monto) para enriquecer los perfiles.
- Evaluar Gaussian Mixture Models (GMM) como alternativa probabilística a K-Means.
- Implementar pipeline con MLflow para versionar modelos y facilitar reentrenamiento mensual.
- Desarrollar un dashboard interactivo (Tableau / Streamlit) para que equipos de negocio consulten segmentos en tiempo real.
- Aplicar el modelo a datos de clientes nuevos como sistema de clasificación de entrada.

9.3 Escalabilidad

- El pipeline Python está diseñado de forma modular. Para aplicarlo a nuevos datos, basta con ejecutar `segmentacion_clientes.py` apuntando al nuevo CSV.
- El scaler y el modelo K-Means pueden serializarse con `joblib` para inferencia en producción sin reentrenamiento.
- Se recomienda reentrenar cada trimestre o cuando el volumen de nuevos registros supere el 20% del conjunto original.

10. Entregables del Proyecto

Archivo	Descripción
<code>segmentacion_clientes.py</code>	Script Python completo con pipeline de ML
<code>segmentacion_clientes.ipynb</code>	Notebook Jupyter con el desarrollo paso a paso
<code>informe_final.docx</code>	Este informe con conclusiones y recomendaciones
<code>README.md</code>	Guía de instalación y ejecución del proyecto
<code>visualizaciones/01_pca_varianza.png</code>	Varianza explicada por componentes PCA
<code>visualizaciones/02_pca_vs_tsne.png</code>	Comparación PCA vs t-SNE
<code>visualizaciones/03_codo_silueta.png</code>	Método del codo y silueta
<code>visualizaciones/04_clustering_pca.png</code>	Clústeres en espacio PCA
<code>visualizaciones/05_clustering_tsne.png</code>	Clústeres en espacio t-SNE
<code>visualizaciones/06_dendrograma.png</code>	Dendrograma jerárquico Ward
<code>visualizaciones/07_silueta_kmeans.png</code>	Gráfico de silueta K-Means
<code>visualizaciones/08_heatmap_clusters.png</code>	Heatmap de perfiles por clúster
<code>visualizaciones/09_distribuciones_clusters.png</code>	Distribuciones por segmento
<code>visualizaciones/10_comparativa_silueta.png</code>	Comparativa de silueta entre algoritmos