

INFORME TÉCNICO

Predicción de Compra de Clientes E-Commerce

Machine Learning Escalable con Apache Spark MLlib

Fecha: Marzo 2026
Equipo de Data Science — Alkemy

1. Resumen Ejecutivo

Este informe presenta los resultados de la implementación de un modelo de Machine Learning escalable para predecir la probabilidad de compra de clientes en una plataforma de e-commerce. Utilizando Apache Spark MLlib, se procesaron más de 100.000 registros de forma distribuida, evaluando dos arquitecturas de clasificación supervisada: Regresión Logística y Random Forest.

El modelo de Random Forest obtuvo el mejor desempeño con un AUC-ROC de 0.9187 y una precisión del 85.4%, superando a la Regresión Logística en todas las métricas evaluadas. El pipeline implementado es completamente escalable y puede adaptarse a decenas de millones de registros sin modificaciones sustanciales.

2. Contexto y Objetivo

La empresa enfrenta un crecimiento exponencial en el volumen de datos generados diariamente: registros de navegación, historial de compras y calificaciones de productos. Las herramientas tradicionales de Machine Learning han alcanzado sus límites de escalabilidad, generando cuellos de botella en el pipeline analítico.

2.1 Objetivo Principal

Construir e implementar un modelo de clasificación supervisada que prediga, con alta precisión, si un cliente realizará una compra en los próximos días, habilitando la personalización de campañas publicitarias en tiempo real.

2.2 Criterios de Éxito

- Superar un AUC-ROC de 0.85 en el conjunto de prueba

- Tiempo de entrenamiento inferior a 30 minutos para 10M de registros
- Pipeline reproducible y desplegable en clúster Spark

3. Flujo de Trabajo

El pipeline de procesamiento sigue las etapas estándar de un proyecto MLlib, garantizando reproducibilidad y escalabilidad en cada paso.

3.1 Preparación de Datos

El dataset contiene 100.000 registros con las siguientes variables de entrada:

- `paginas_vistas_7d` — número de páginas vistas en los últimos 7 días
- `tiempo_sesion_min` — duración promedio de sesión en minutos
- `compras_historicas` — total de compras realizadas por el cliente
- `calificacion_promedio` — promedio de calificaciones de productos visitados
- `dias_ultima_visita` — recencia de la última visita al sitio
- `items_carrito` — productos actualmente en el carrito
- `segmento_cliente` — clasificación del cliente: nuevo, recurrente o vip

La etiqueta objetivo (label) vale 1 si el cliente realizará una compra en los próximos días y 0 en caso contrario. La distribución de clases presenta un desbalanceo moderado (~25% positivos), lo cual fue considerado en la selección de métricas.

3.2 Ingeniería de Features

Se aplicó el siguiente pipeline de transformación de MLlib:

- `StringIndexer` convirtió la variable categórica `segmento_cliente` en índice numérico
- `VectorAssembler` ensambló todas las features en un único vector denso
- `StandardScaler` normalizó las features con media 0 y desviación estándar 1 (crítico para Regresión Logística)

3.3 División Train / Test

Los datos fueron divididos en 80% entrenamiento (80.000 registros) y 20% prueba (20.000 registros) con semilla fija (`seed=42`) para garantizar reproducibilidad.

3.4 Ajuste de Hiperparámetros

Se utilizó validación cruzada con 3 folds (`CrossValidator`) sobre las siguientes grillas de hiperparámetros:

- Regresión Logística — `regParam`: [0.01, 0.1, 0.5]; `elasticNetParam`: [0.0, 0.5, 1.0]
- Random Forest — `numTrees`: [50, 100]; `maxDepth`: [5, 10]

El criterio de selección fue el AUC-ROC promedio en los folds de validación.

4. Resultados y Métricas

4.1 Comparativa de Modelos

La siguiente tabla resume el desempeño de ambos modelos evaluados en el conjunto de prueba:

Métrica	Reg. Logística	Random Forest	Interpretación
AUC-ROC	0.8921	0.9187	RF superior
Accuracy	0.8350	0.8612	RF +2.6 pp
Precision	0.8290	0.8540	RF superior
Recall	0.8120	0.8430	RF superior

El modelo de Random Forest superó a la Regresión Logística en todas las métricas, con una ventaja de 2.66 puntos porcentuales en AUC-ROC. Este resultado es esperable dado que Random Forest captura relaciones no lineales entre las variables, mientras que la Regresión Logística asume linealidad.

4.2 Importancia de Features

El análisis de importancia de features del modelo Random Forest revela cuáles son las variables con mayor poder predictivo:

Feature	Importancia	Relevancia	Descripción
items_carrito	0.3214	Alta	Indicador directo de intención de compra
compras_historicas	0.2456	Alta	Comportamiento histórico del cliente
paginas_vistas_7d	0.1832	Media	Nivel de engagement reciente
tiempo_sesion_min	0.1123	Media	Profundidad de exploración
dias_ultima_visita	0.0821	Baja-Media	Recencia del cliente
calificacion_promedio	0.0413	Baja	Satisfacción con productos
segmento_cliente	0.0141	Baja	Clasificación del usuario

Los items en carrito y las compras históricas representan más del 56% de la importancia total del modelo, lo que indica que el comportamiento de intención de compra reciente y el historial son los predictores más poderosos.

4.3 Análisis de Predicciones

Se validaron las predicciones sobre tres perfiles de clientes representativos. El modelo asignó correctamente probabilidades altas a clientes con múltiples items en carrito y perfil vip, y probabilidades bajas a clientes nuevos con baja actividad reciente, demostrando coherencia con el dominio del negocio.

5. Recomendaciones y Mejoras Futuras

5.1 Mejoras en el Modelo

- **Probar GBClassifier de MLlib, que típicamente supera a Random Forest en datos tabulares:** Gradient Boosted Trees (GBT)
- **Aplicar técnicas de sobremuestreo (SMOTE) o ajustar classWeightCol para mejorar la detección de la clase minoritaria:** Tratamiento del desbalanceo

- **Incorporar variables derivadas como tasa de conversión histórica, tiempo entre visitas y valor promedio del carrito:** Feature engineering avanzado
- **Representar la secuencia de páginas visitadas con modelos de secuencia para capturar patrones de navegación:** Embeddings de sesión

5.2 Mejoras en Infraestructura

- **Migrar los datos de entrada a formato Delta para habilitar time travel y transacciones ACID:** Almacenamiento en Delta Lake
- **Implementar un pipeline de CI/CD para reentrenar el modelo semanalmente con los últimos datos:** Reentrenamiento automático
- **Integrar MLflow para registrar experimentos, versionar modelos y gestionar el ciclo de vida de ML:** MLflow para tracking
- **Usar Spark Structured Streaming para generar predicciones en tiempo real sobre nuevos eventos de navegación:** Inferencia en streaming
- **Implementar alertas cuando la distribución de las features de entrada se aleje del baseline de entrenamiento:** Monitoreo de data drift

5.3 Consideraciones de Negocio

- Umbral de decisión ajustable — el umbral de 0.5 para clasificar como compra puede optimizarse según el costo relativo de falsos positivos y negativos
- Segmentación dinámica — usar las probabilidades del modelo (no solo la clasificación binaria) para crear campañas escalonadas según nivel de propensión
- A/B Testing — validar el impacto del modelo en métricas de negocio reales antes de despliegue completo

6. Conclusiones

La implementación del pipeline de Machine Learning escalable con Apache Spark MLlib demostró ser técnicamente viable y eficiente para el volumen de datos del cliente. El modelo de Random Forest seleccionado alcanza un AUC-ROC de 0.9187, superando el umbral de éxito establecido de 0.85.

La arquitectura distribuida garantiza que el pipeline pueda escalar linealmente con el volumen de datos sin requerir cambios en el código. La integración con las herramientas del ecosistema Spark (Delta Lake, MLflow, Structured Streaming) permitirá evolucionar hacia un sistema de predicción en tiempo real en fases posteriores.

Se recomienda proceder al despliegue del modelo en entorno productivo, comenzando con un A/B test controlado sobre el 20% del tráfico, y paralelamente iniciar el desarrollo de las mejoras identificadas en la sección 5.